

Diccionario de Palabras Clave — Semana 1

Bootcamp: De Cero a Data Engineer - Databricks SQL

Bloque temático: Fundamentos Databricks SQL | Clase Grupal

Instructor: Luciano Argolo | www.LucianoArgolo.com

Todos los términos técnicos y de jerga que aparecieron en la clase grupal de la Semana 1, explicados de forma simple para que cualquier persona que arranca de cero pueda entenderlos.



Roles y personas

Del mundo de datos



Arquitectura y capas

Landing → Bronze → Silver
→ Gold



Bases de datos

Tablas, claves, JOINS



Procesos y herramientas

Pipelines, ELT, Databricks, DBT



Gobernanza y accesos

Permisos, ownership, PII

Roles y personas

Término	¿Qué es?
Analista de datos (Data Analyst)	Toma datos ya preparados y los analiza: gráficos, reportes, dashboards. No construye pipelines; usa lo que el ingeniero de datos dejó listo.
Analista funcional	Traduce lo que el negocio necesita a un lenguaje que los técnicos entiendan. Recibe el pedido del jefe, lo mastica y te lo pasa como requerimiento. A veces no existe y te toca a vos.
C-Level	Los ejecutivos más altos: CEO, CTO, CFO. La "C" viene de "Chief". Si "el C-Level quiere los datos", el pedido viene de la dirección.
Data Engineer (Ingeniero de datos)	Construye y mantiene los sistemas por donde pasan los datos. Diseña pipelines, mueve datos, limpia, transforma y asegura calidad.
Data Scientist (Científico de datos)	Aplica estadística y programación para encontrar patrones y hacer predicciones. Necesita datos ya limpios (trabajo del Data Engineer).
Data Steward	Cuida la calidad y reglas de uso de un conjunto de datos. Decide las reglas de negocio sobre esos datos.
Dueño del dato (Data Owner)	Persona o área responsable de un conjunto de datos. Tiene la última palabra sobre qué hacer con ellos.
Stakeholder	Cualquier persona con interés o afectada por un proyecto: tu jefe, el cliente, otro equipo, el área de ventas.

Arquitectura y capas de datos

Término	¿Qué es?
Arquitectura de datos	El diseño general de cómo se organizan, almacenan y mueven los datos. Como el plano de una casa, pero para datos.
Landing (capa)	Zona temporal de descarga: los datos llegan ahí desde una fuente externa y después se mueven a Bronze.
Bronze (capa)	Primera capa. Datos crudos, tal como llegan, sin limpiar. La materia prima.
Silver (capa)	Capa intermedia. Datos ya limpiados: sin duplicados, formatos corregidos, nombres estandarizados.
Gold (capa)	Capa final. Datos listos para el negocio: reportes, dashboards y análisis se hacen acá. El producto terminado.
Capa semántica	Capa de acceso encima de Gold para que otras áreas consulten sin tocar los datos originales. Como una vidriera: ven y usan, pero no entran al depósito.
Esquema (Schema)	Estructura que define qué tablas hay, qué columnas tiene cada una y qué tipo de dato guarda. El índice del libro de los datos.

Conceptos de bases de datos

Término	¿Qué es?
Tabla (table)	Forma básica de organizar datos: filas (registros) y columnas (atributos). Como una hoja de Excel.
Clave primaria (Primary Key)	Campo que identifica de forma única cada fila. No puede repetirse ni estar vacío. Ej: un DNI o un ID de producto.
Clave foránea (Foreign Key)	Campo que apunta a la clave primaria de otra tabla. Sirve para conectar tablas entre sí.
Integridad referencial	Regla que asegura que las relaciones entre tablas sean coherentes. Si un pedido dice "cliente #42", ese cliente tiene que existir.
JOIN	Operación SQL que combina datos de dos o más tablas usando un campo en común. Si el campo no es único, puede duplicar registros.
Subquery	Una query dentro de otra query. Primero resuelve la consulta interna y usa el resultado en la consulta principal.
Query	Consulta a una base de datos escrita en SQL. Ej: "dame todos los clientes de México que compraron en enero".
Nulos (NULL)	Campo vacío, sin dato. No es cero ni espacio en blanco: es ausencia total de información. Muchos nulos = posible problema de calidad.
Duplicados	Registros repetidos. Causan conteos inflados, reportes incorrectos y decisiones equivocadas.
Valores fuera de rango	Datos que no tienen sentido: edad de -5 años, precio 0 donde no debería, fecha del año 3000.

 **Problemas de calidad más comunes:** NULL sin justificación, duplicados en tablas clave, y valores fuera de rango son las señales de alerta más frecuentes en cualquier pipeline de datos.

Procesos y herramientas

Término	¿Qué es?
Pipeline	Secuencia automatizada de pasos que mueven y transforman datos. Como una cadena de montaje: entran crudos, salen limpios.
ELT (Extract, Load, Transform)	Extraer datos, cargarlos en un destino, y recién ahí transformarlos. Orden más común en herramientas modernas.
Orquestación	Coordinar y automatizar múltiples tareas en orden. Como un director de orquesta: si un paso falla, decide qué hacer.
Rollback	Volver datos o un sistema a un estado anterior que funcionaba. Como un "Ctrl+Z" para bases de datos.
Target (destino)	El lugar donde van los datos después de ser procesados. La tabla final donde se depositan.
Producción (productivo)	Ambiente con datos reales y usuarios reales. Si falla acá, afecta al negocio directamente.
Databricks	Plataforma en la nube para trabajar con grandes cantidades de datos (SQL, Python, etc.). Herramienta principal del bootcamp.
DBT (Data Build Tool)	Herramienta para escribir transformaciones SQL, organizarlas y ejecutarlas automáticamente. Permite versionar y rollbackear.
Apache NiFi	Herramienta para mover datos automáticamente entre sistemas. Cinta transportadora de datos, incluso millones de registros.
Kaggle	Sitio web con datasets gratuitos para practicar, competencias y aprendizaje. Ideal para proyectos personales.
Dashboard (tablero)	Pantalla visual con gráficos y números que resume información del negocio. Como el tablero de un auto.
Web scraping	Extraer datos de páginas web de forma automatizada. Un programa visita sitios y "raspa" la información que necesitás.

Gobernanza, accesos y otros términos

Término	¿Qué es?
Data Governance	Reglas y procesos que definen quién puede ver, modificar o usar los datos. Las normas del edificio: quién tiene llave de qué puerta.
Data Mesh	Enfoque donde cada área del negocio es dueña de sus propios datos, en vez de un equipo central que maneja todo.
Ownership (propiedad)	Quién es responsable de una tabla, dashboard o pipeline. Si queda en una sola persona y se va, nadie puede mantenerlo.
PAM (Privileged Access Management)	Sistema que centraliza accesos privilegiados. Da acceso temporal previa aprobación. Común en bancos.
PII (Personally Identifiable Information)	Datos que identifican a una persona: nombre, DNI, dirección, email. Son sensibles y hay que protegerlos.
Licencia (de software)	Permiso pago para usar una herramienta. Si te echan y cancelan tu licencia, se pierde el acceso.
Backbone	"Columna vertebral". El equipo de data es la base que sostiene todo. Si los datos fallan, falla todo lo demás.
Escalar	Llevar un problema a alguien con más autoridad o contexto cuando no podés resolverlo solo.
Hipótesis	Suposición sobre qué pasa con los datos, basada en el contexto. Se formula ANTES de analizar para tener un norte.
Reingeniería	Rehacer un trabajo porque estaba mal planteado desde el inicio. Desperdicio de tiempo por requerimientos incompletos.
Startup	Empresa nueva y pequeña, con pocos recursos, poca documentación y equipos donde una persona hace varios roles.