

Ejercicios Prácticos - Semana 1

Fundamentos + Databricks + SQL Base

Bootcamp: Fundamentos de Ingeniería de Datos

Tema: SQL Base - JOINS y Agregaciones

Dataset: `samples.nyctaxi.trips` (datos de ejemplo de Databricks)



Instrucciones

1. Crear un nuevo notebook en Databricks: Semana_1_Ejercicios
2. Usar %sql al inicio de cada celda SQL
3. Ejecutar cada query y verificar resultados



Tips importantes:

- Si te trabas, revisa los ejemplos del notebook de solución
- Verifica tus resultados: ¿tienen sentido los números?
- Documenta tus queries con comentarios
- Usá la IA cuando haya funciones que no conozcas en Databricks para que te las genere, y pasale como contexto algunos datos para que comprenda mejor



PARTE 1: Consultas Básicas de Exploración

1	Tu primera query Objetivo: Familiarizarte con Databricks y ejecutar tu primera query. Pregunta: ¿Cuántos viajes hay en total en el dataset de NYC Taxi Trips? Pista: Usa la función COUNT(*) sobre la tabla samples.nyctaxi.trips
2	Explorar estructura Objetivo: Entender qué columnas tiene el dataset. Pregunta: ¿Qué columnas tiene la tabla samples.nyctaxi.trips? ¿Qué tipos de datos tienen? Pista: Usa DESCRIBE o SELECT * LIMIT 0 para ver la estructura
3	Viajes más largos Objetivo: Encontrar valores extremos en los datos. Pregunta: ¿Cuál es el viaje más largo (mayor distancia) en el dataset? ¿Y el más corto (excluyendo ceros)? Pista: Usa MAX() y MIN() con WHERE para filtrar valores inválidos
4	Estadísticas básicas Objetivo: Calcular promedios y estadísticas descriptivas. Pregunta: ¿Cuál es el promedio de tarifa (fare_amount) y distancia (trip_distance) de los viajes? Pista: Usa AVG() y ROUND() para formatear decimales
5	Viajes recientes Objetivo: Ordenar y limitar resultados. Pregunta: Muestra los 20 viajes más recientes con su fecha, distancia y tarifa. Pista: Usa ORDER BY con DESC y LIMIT

PARTE 2: Filtros y Condiciones

01

Viajes largos

Objetivo: Aplicar filtros simples con WHERE.

Pregunta: Muestra todos los viajes que tienen una distancia mayor a 10 millas.

Pista: Usa WHERE trip_distance > 10

02

Múltiples condiciones

Objetivo: Combinar condiciones con AND.

Pregunta: Encuentra viajes que tengan distancia mayor a 5 millas Y tarifa mayor a \$10.

Pista: Usa WHERE ... AND ...

03

Condiciones con OR

Objetivo: Usar OR para condiciones alternativas.

Pregunta: Muestra viajes que tengan distancia mayor a 20 millas O tarifa mayor a \$100.

Pista: Usa WHERE ... OR ...

04

Rango de valores

Objetivo: Usar BETWEEN para rangos.

Pregunta: Encuentra viajes con tarifa entre \$10 y \$20.

Pista: Usa WHERE fare_amount BETWEEN 10 AND 20

05

Lista de valores

Objetivo: Filtrar por múltiples valores específicos.

Pregunta: Muestra viajes que comenzaron en los códigos postales 10009, 10013 o 10014.

Pista: Usa WHERE pickup_zip IN (10009, 10013, 10014)

PARTE 3: Agregaciones

Ejercicio 3.1: Conteo básico

Objetivo: Contar registros.

Pregunta: ¿Cuántos viajes hay en total?

Pista: `SELECT COUNT(*) FROM ...`

Ejercicio 3.2: Sumas

Objetivo: Sumar valores numéricos.

Pregunta: ¿Cuál es el total de tarifas y la distancia total recorrida por todos los viajes?

Pista: Usa `SUM()` para ambas columnas

Ejercicio 3.3: Promedios

Objetivo: Calcular promedios.

Pregunta: ¿Cuál es la distancia promedio y la tarifa promedio de los viajes? (excluye valores cero)

Pista: Usa `AVG()` con `WHERE` para filtrar ceros

Ejercicio 3.4: Mínimos y máximos

Objetivo: Encontrar valores extremos.

Pregunta: ¿Cuál es la tarifa mínima, máxima, distancia mínima y máxima? (excluye valores cero)

Pista: Usa `MIN()` y `MAX()` con filtros

PARTE 4: GROUP BY y PARTE 5: HAVING

Ejercicio 4.1: Agrupar por zona

Objetivo: Agrupar datos y calcular métricas por grupo.

Pregunta: ¿Cuántos viajes hay por zona de inicio (pickup_zip)? ¿Cuál es el ingreso total y promedio por zona? Ordena por ingreso total descendente.

Pista: Usa GROUP BY pickup_zip, COUNT(*), SUM(fare_amount), AVG(fare_amount), ORDER BY

Ejercicio 4.2: Viajes por día de la semana

Objetivo: Agrupar por fecha y calcular estadísticas.

Pregunta: ¿Cuántos viajes hay por día de la semana? ¿Cuál es la distancia promedio por día?

Pista: Usa GROUP BY

Ejercicio 4.3: Viajes por hora

Objetivo: Analizar patrones horarios.

Pregunta: ¿Cuántos viajes hay por hora del día? ¿Cuál es la tarifa promedio por hora? Ordena por hora.

Pista: Usa y GROUP BY

Ejercicio 5.1: Filtrar grupos grandes

Objetivo: Filtrar grupos después de agrupar.

Pregunta: Muestra solo las zonas que tienen más de 1,000 viajes.

Pista: Usa GROUP BY con HAVING COUNT(*) > 1000

Ejercicio 5.2: Días con muchos viajes

Objetivo: Identificar días con alta actividad.

Pregunta: ¿Qué días tuvieron más de 200 viajes? Muestra la fecha, cantidad de viajes y tarifa promedio.

Pista: GROUP BY, HAVING, ORDER BY y LIMIT

Ejercicio 5.3: Horas pico

Objetivo: Identificar horas con mayor actividad.

Pregunta: ¿Qué horas tienen más de 1,000 viajes? Ordena por cantidad de viajes descendente.

Pista: GROUP BY, HAVING COUNT(*) > 1000

PARTE 6: Análisis Combinado



Ejercicio 6.1: Análisis completo por zona

Objetivo: Combinar WHERE, GROUP BY y HAVING.

Pregunta: Para zonas con más de 1,000 viajes, muestra: zona, cantidad de viajes, tarifa máxima, promedio y mínima. Solo incluye viajes con tarifa mayor a \$5 y distancia mayor a 0.

Pista: Usa WHERE para filtrar registros, GROUP BY para agrupar, HAVING para filtrar grupos



Ejercicio 6.2: Categorizar viajes por distancia

Objetivo: Usar CASE WHEN para crear categorías.

Pregunta: Categoriza los viajes por distancia:

- Corto: < 2 millas
- Medio: 2-5 millas
- Largo: 5-10 millas
- Muy largo: > 10 millas

Luego agrupa por categoría y muestra: categoría, cantidad de viajes, tarifa promedio, distancia promedio. Solo categorías con más de 100 viajes.

Pista: Usa CASE WHEN en el SELECT y también en el GROUP BY



Ejercicio 6.3: Top viajes

Objetivo: Ordenar y limitar resultados.

Pregunta: Muestra los 10 viajes más largos (mayor distancia) con su fecha, distancia y tarifa.

Pista: Usa ORDER BY trip_distance DESC LIMIT 10



Checklist de Finalización

Progreso de Ejercicios

- Completé todos los ejercicios de la Parte 1
- Completé todos los ejercicios de la Parte 2
- Completé todos los ejercicios de la Parte 3
- Completé todos los ejercicios de la Parte 4
- Completé todos los ejercicios de la Parte 5
- Completé todos los ejercicios de la Parte 6

¡Éxito con los ejercicios! 