

Guía de Preguntas de Entrevista — Semana 2

Bootcamp: De Cero a Data Engineer - Databricks SQL

Bloque temático: **ANALIZAR** | Clase Grupal

Instructor: Luciano Argolo

Esta guía recopila las preguntas de entrevista técnica practicadas en la clase grupal de la Semana 2. Cada pregunta incluye la respuesta esperada y por qué importa en una entrevista real. Usá esta guía para prepararte: **practicá responder en voz alta antes de leerla.**

SQL Avanzado

CTEs, Window Functions, GROUP BY vs PARTITION BY

Git & GitHub

GitFlow, hotfix, control de versiones

Arquitectura de Datos

EDA, Medallion, landing vs bronze

Gobernanza

Unity Catalog, datos sensibles, métricas de pipeline

Preguntas 1 a 3: Window Functions y Agrupación

Pregunta 1: ¿Cuál es la diferencia entre ROW_NUMBER y RANK?

- **ROW_NUMBER:** asigna un número secuencial único a cada fila, sin importar empates (1, 2, 3, 4...).
- **RANK:** asigna el mismo número a filas empatadas y salta posiciones. Si dos filas empatan en el puesto 2, la siguiente es puesto 4.
- **DENSE_RANK:** similar a RANK pero no salta posiciones: si hay empate en el 2, la siguiente es 3.

 **Clave para entrevistas:** Pregunta clásica. Demuestra que entendés la diferencia entre funciones de ventana y sabés cuándo usar cada una. ROW_NUMBER es clave para eliminar duplicados.

Pregunta 2: ¿Cuál es la diferencia entre WHERE y HAVING?

- **WHERE** filtra filas antes de la agrupación (GROUP BY). Opera sobre datos individuales.
- **HAVING** filtra después de la agrupación. Opera sobre los resultados del GROUP BY.
- Orden de ejecución: FROM → WHERE → GROUP BY → HAVING → SELECT → ORDER BY

 **Clave para entrevistas:** Demuestra que entendés el orden de ejecución de SQL. Si decís "WHERE filtra antes y HAVING después", ya ganaste puntos.

Pregunta 3: Top 3 de zonas más caras. ¿GROUP BY o Window Function?

- Para un **ranking simple** (top N), GROUP BY + ORDER BY + LIMIT es suficiente y más directo.
- Para **mantener la granularidad** de las filas (ver cada registro individual con su ranking), se usa una Window Function con ROW_NUMBER o RANK.
- La elección depende de si necesitás datos agregados (GROUP BY) o datos detallados con contexto (Window Function).

 **Clave para entrevistas:** No hay respuesta "correcta" única. Lo que evalúan es que sepas justificar cuándo usar cada enfoque según el requerimiento.

Preguntas 4 a 6: CTEs, PARTITION BY y Self-Joins

Pregunta 4: ¿Cuál es la diferencia entre GROUP BY y PARTITION BY?

- Ambos agrupan datos, pero en contextos diferentes.
- **GROUP BY** opera sobre la query completa y colapsa filas: el resultado tiene una fila por grupo.
- **PARTITION BY** opera dentro de una Window Function y mantiene todas las filas originales.
- **PARTITION BY** es el equivalente a **GROUP BY** pero exclusivamente dentro del contexto de una Window Function.

📄 🎯 **Clave para entrevistas:**
Muestra comprensión profunda de cómo funcionan las Window Functions internamente.

Pregunta 5: ¿Hay diferencia de rendimiento entre una CTE y una subquery?

- No hay diferencia significativa de rendimiento. El motor las optimiza de forma similar.
- La ventaja de las CTEs es **legibilidad y mantenibilidad** del código.
- Las CTEs permiten encadenar transformaciones con nombres descriptivos, mientras que las subqueries anidan código y se vuelven difíciles de leer.

📄 🎯 **Clave para entrevistas:**
La respuesta corta es "rendimiento similar, legibilidad superior".
Mencioná que las CTEs son la versión limpia de las subqueries.

Pregunta 6: ¿Cuándo usarías una Window Function en vez de un self-join?

- Siempre que sea posible, **preferir Window Functions**. Son más performantes porque están optimizadas para ese uso.
- Los self-joins pueden traer conjuntos de datos más grandes de lo necesario.
- Si necesitás múltiples cálculos (LAG, promedio, ranking), con Window Functions se resuelve en una query. Con self-joins necesitarías múltiples CTEs y JOINS.
- Self-join solo si no hay Window Function que resuelva el problema o si el motor no las soporta.

📄 🎯 **Clave para entrevistas:**
Mencioná la eficiencia y la legibilidad. Si podés dar un ejemplo concreto (como LAG para comparar con el mes anterior vs. hacer un self-join), mejor.

Preguntas 7 a 9: Control de Versiones y GitFlow

Pregunta 7: Describí el flujo de GitFlow para implementar una nueva funcionalidad.

1. Crear una branch desde main:
`git checkout -b feature/nombre-funcionalidad`
2. Trabajar en esa branch: hacer commits y pushes periódicos.
3. Al terminar, abrir un **Pull Request (PR)** para revisión.
4. El líder del equipo revisa el código y aprueba.
5. Se hace merge a `develop`, se prueba, y luego se pasa a `main/producción`.



🎯 Clave para

entrevistas: Que sepas nombrar las ramas (main, develop, feature, hotfix) y el flujo completo. No hace falta que sea perfecto, pero sí que demuestres que trabajaste en equipo con Git.

Pregunta 8: Producción se rompió a las 3am. ¿Qué hacés?

- Crear un **hotfix**: una branch directa desde main para arreglar el problema.
- No seguir el flujo completo de GitFlow (no pasar por develop, no esperar revisiones largas).
- Aplicar el fix, testearlo mínimamente, hacer merge directo a main y deployar.
- Al día siguiente, documentar el incidente y hacer merge del hotfix a develop para que quede sincronizado.



🎯 Clave para

entrevistas: Demuestra que sabés priorizar: velocidad sobre proceso cuando producción está caído.

Pregunta 9: ¿Cuál es el problema de no usar control de versiones (GitHub)?

- No hay historial de cambios: no sabés quién cambió qué ni cuándo.
- No podés volver atrás si algo se rompe.
- Cuando varias personas trabajan en el mismo archivo, uno pisa el trabajo del otro sin posibilidad de resolver conflictos de forma ordenada.
- No tenés un portfolio profesional para mostrar en entrevistas.



🎯 Clave para

entrevistas: Esta pregunta evalúa si entendés el "por qué" de Git, no solo el "cómo".

Preguntas 10 a 12: EDA, Muestreo y Tablas Managed vs External

Pregunta 10: ¿Cuál es el riesgo de no hacer EDA antes de cargar datos al pipeline?

- No tenés contexto de qué estás procesando: tipos de datos, nulos, outliers, distribución.
- Podés cargar datos basura que contaminen las capas Silver y Gold.
- Los modelos o reportes downstream producen resultados incorrectos.
- Es un estándar de la industria que no se puede saltar. Si te lo piden, hacelo igual y después volvé a revisar.

📌 **Clave para entrevistas:**
Mostrá que entendés que EDA es prevención, no opcional.

Pregunta 11: Tabla con 100 mil millones de registros. ¿EDA sobre toda la tabla o sobre una muestra?

- Sobre una **muestra representativa**, por eficiencia de cómputo y costos.
- Tomar una muestra que sea estadísticamente significativa (no las primeras N filas, sino una muestra aleatoria o estratificada).
- Validar que la muestra represente la distribución real de los datos.

📌 **Clave para entrevistas:**
La respuesta "muestra" es obvia. Lo que importa es que justifiques por qué (costos, tiempo) y cómo (muestra representativa, no arbitraria).

Pregunta 12: ¿Cuál es la diferencia entre una tabla managed y una external en Databricks?

- **Managed:** los datos se almacenan internamente. Si borrás la tabla (DROP TABLE), se pierden los datos.
- **External:** la tabla apunta a datos en otra ubicación. Si borrás la tabla, los datos siguen existiendo.
- **Cuándo usar external:** Bronze leyendo de landing (evita duplicar datos), compartir datos entre equipos, leer datos que otro proceso actualiza.
- **Cuándo usar managed:** Silver y Gold, donde los datos ya están transformados y son propios del pipeline.

📌 **Clave para entrevistas:**
Saber explicar cuándo usar cada una demuestra criterio de diseño, no solo conocimiento técnico.

Preguntas 13 a 15: Unity Catalog, Métricas y Estadística

Pregunta 13: ¿Cómo protegerías los datos sensibles a lo largo de un pipeline?

- Usar **Unity Catalog** para gobernanza centralizada.
- Accesos granulares: a nivel catálogo, esquema, tabla, columna o fila.
- **Column masking** para datos PII (DNI, nombre, email): la persona ve la tabla pero no el contenido sensible.
- **Row-level security** con funciones que filtran según el usuario conectado.
- Cumplir normativas como GDPR (Europa) o CCPA (California).



Clave para entrevistas:

Si no sabés la respuesta exacta, usá la ambigüedad a tu favor. Empezá por lo general ("usaría Unity Catalog para controlar accesos") y bajá al detalle si te preguntan más.

Pregunta 14: ¿Qué métricas usarías para medir la confiabilidad de un pipeline?

- **Calidad de datos entre capas:** comparar % de nulos, tipos de datos, cardinalidad entre landing/bronze/silver/gold. Si los nulos aumentan entre capas, algo está mal.
- **Tasa de éxito de ejecución:** cuántas veces el pipeline se completa sin fallar (medible con Airflow u orquestadores similares).
- **Punto de referencia:** siempre comparar contra los datos de landing/fuente. No se puede mejorar lo que no se recibió.
- **Latencia:** cuánto tarda el pipeline en procesar los datos desde la fuente hasta Gold.



Clave para entrevistas:

Lo que buscan es que no digas solo "que no falle". Mencioná calidad de datos, ejecución y punto de referencia.

Pregunta 15: ¿Diferencia entre moda, promedio y mediana?

- **Moda:** el valor que más se repite.
- **Promedio (media):** suma de todos los valores dividida por la cantidad. Es sensible a outliers.
- **Mediana:** el valor del medio cuando los datos están ordenados. Es robusta ante outliers.
- Ejemplo clásico: en Medina (Washington), el promedio de ingresos es altísimo por Bill Gates y Jeff Bezos, pero la mediana refleja mejor la realidad de los residentes normales.



Clave para entrevistas:

Pregunta básica pero que muchos fallan. Si podés dar el ejemplo del sesgo, demostrarás comprensión real.

Consejos para Entrevistas Técnicas

Lo que evalúan	Cómo demostrarlo
Comprensión conceptual, no solo sintaxis	Explicá el "por qué" antes del "cómo". No recites código, explicá la lógica.
Criterio de diseño	Justificá tus decisiones: "usaría X porque en este caso..."
Manejo de la incertidumbre	Si no sabés algo, usá la ambigüedad: repetí la pregunta, empezá por lo general, bajá al detalle.
Comunicación técnica	Practicá explicar conceptos en voz alta. La cámara encendida en clase sirve para esto.
Experiencia real vs. teoría	Mencioná situaciones reales (aunque sean del bootcamp): "cuando limpié este dataset encontré que..."
Pensamiento crítico	No respondas solo lo que preguntan: agregá trade-offs, excepciones, casos borde.

Consejo final: Practicá las preguntas en voz alta, no solo leyéndolas. La diferencia entre saber la respuesta y poder articularla fluidamente en una entrevista es enorme. Aprovechá las clases grupales para ensayar con la cámara encendida.

Instructor: **Luciano Argolo**

www.LucianoArgolo.com