Ejercicios Semana 3: Arquitectura Medallion

BOOTCAMP: FUNDAMENTOS DE INGENIERÍA DE DATOS

BLOQUE TEMÁTICO: ARQUITECTURA MEDALLION | PRÁCTICA COMPLEMENTARIA

Instructor: **Luciano Argolo** | www.LucianoArgolo.com

Estrategia de Abordaje para los Ejercicios

Esta semana vas a trabajar ejercicios de arquitectura Medallion y pipelines de datos. Es normal encontrar trabas, así que la idea es avanzar de forma ordenada, eficiente y sin perder el ritmo.

Consejo clave: Si un ejercicio se complica demasiado, no te quedes trabado: seguí con los demás y después lo retomamos en la clase de consultas.

Identificá el bloqueo

Detectá rápido qué parte te está frenando para no perder tiempo.

Avanzá en paralelo

Seguí con otros ejercicios y mantené el progreso en movimiento.

Volvé con otra mirada

Retomá el problema después: una segunda pasada suele destrabar todo.

Estructura General de los Ejercicios

Estos ejercicios te guían paso a paso para construir tu primera Arquitectura Medallion completa: desde verificar el catálogo hasta analizar datos limpios en Silver.

01

Parte 1 — Entender la Arquitectura

Verificar catálogo, crear esquemas

02

Parte 2 — Crear Tabla Silver

Diseño, DDL, verificación, decisiones de diseño

03

Parte 3 — Pipeline Bronze → Silver

Limpieza, tipado, deduplicación, inserción paso a paso

04

Parte 4 — Análisis sobre Silver

Las mismas herramientas de Semana 1, ahora sobre tus datos

05

Parte 5 — Verificar el Pipeline

Validación end-to-end y preview de Semana 4

PARTE 1

Entender la Arquitectura Medallion

Ejercicio 1.1: Verificar catálogo y explorar Bronze

Objetivo: Confirmar que el catálogo y la tabla Bronze existen antes de empezar.

Paso 1: Usá `SHOW SCHEMAS IN bootcamp` para listar los esquemas existentes.

Paso 2: Ejecutá un `COUNT(*)` sobre `bootcamp.bronze.properties_bronze` para verificar que hay datos sin ver todo el contenido.

Tips:

- Si no recordás el nombre exacto de la tabla, usá `SHOW TABLES IN bootcamp.bronze`
- `COUNT(*)` es la forma más rápida de verificar que una tabla tiene datos

Ejercicio 1.2: Crear esquemas Silver y Gold

Objetivo: Crear los esquemas que contendrán los datos limpios (Silver) y modelados (Gold).

Paso 1: Creá el esquema Silver con `CREATE SCHEMA IF NOT EXISTS`. Agregá un `COMMENT` que describa su propósito.

Paso 2: Creá el esquema Gold siguiendo el mismo patrón, cambiando el comentario para reflejar que Gold es para modelado de negocio.

Paso 3: Verificá las 3 capas con `SHOW SCHEMAS IN bootcamp`. Deberías ver: bronze, silver, gold.

Tips:

- `IF NOT EXISTS` evita errores si el esquema ya fue creado
- La sintaxis completa incluye el catálogo: `bootcamp.silver`, `bootcamp.gold`

PARTE 2

Crear Tabla Silver

Ejercicio 2.1: Diseñar estructura de tabla Silver

Objetivo: Definir qué columnas necesita la tabla Silver basándote en el EDA de Semana 2.

📍 Ubicación

`partido`, `region`

Derivadas de `zona` en Bronze

💰 Precio

`precio`, `moneda`, `expensas`, `precio_por_m2`

🏠 Características

`ambientes`, `metros_cuadrados_totales`, `metros_cuadrados_cubiertos`, `antiguedad`, `cochera`

🗂️ Metadata

`_source_table`, `_processing_timestamp`

Tips:

- Revisa el EDA de Semana 2 — ahí identificaste las columnas importantes
- Tenés el archivo `datasets/zonas_subzonas_case.sql` con el mapeo SQL completo: zona → partido y region

---

Ejercicio 2.2: Crear tabla Silver

Objetivo: Materializar el diseño con `CREATE TABLE` usando Delta Lake.

1. Delta Lake

Usá `CREATE TABLE` con `USING DELTA`

2. Tipos de datos

`DECIMAL(15,2)` para precios y superficies, `INT` para contadores, `BOOLEAN` para campos binarios

3. Metadata

`TIMESTAMP` para procesamiento, `STRING` para origen

4. Documentación

Usá `TBLPROPERTIES` y `COMMENT` en cada columna

Ayudas:

- ¿Por qué no alcanza con la columna `zona` original? Porque la misma localidad llega escrita distinto según la fuente (ZonaProp, Argenprop, LiderProp)
- ¿Qué es `TBLPROPERTIES` y para qué sirve?

PARTE 2 — CONTINUACIÓN

Verificación y Decisiones de Diseño

Ejercicio 2.3: Verificar estructura creada

Objetivo: Confirmar que la tabla se creó con los tipos de datos correctos.

Paso 1: Ejecutá `DESCRIBE bootcamp.silver.propiedades` para ver columnas y tipos.

Paso 2: Ejecutá `DESCRIBE EXTENDED bootcamp.silver.propiedades` para ver metadata completa incluyendo TBLPROPERTIES.

Ejercicio 2.4: Pregunta de diseño

Objetivo: Pensar en decisiones de arquitectura antes de construir el pipeline.

Pregunta: ¿Por qué vamos a crear vistas temporales (Ejercicio 3.1) antes de insertar en Silver? ¿Qué pasaría si hiciéramos `INSERT INTO Silver` directamente desde Bronze?

Pensá en:

- ¿Qué pasa si el CAST falla en mitad de la inserción?
- ¿Cómo verificás que los datos transformados son correctos antes de persistirlos?
- ¿Qué ventaja tiene poder hacer SELECT sobre la vista antes de insertar?

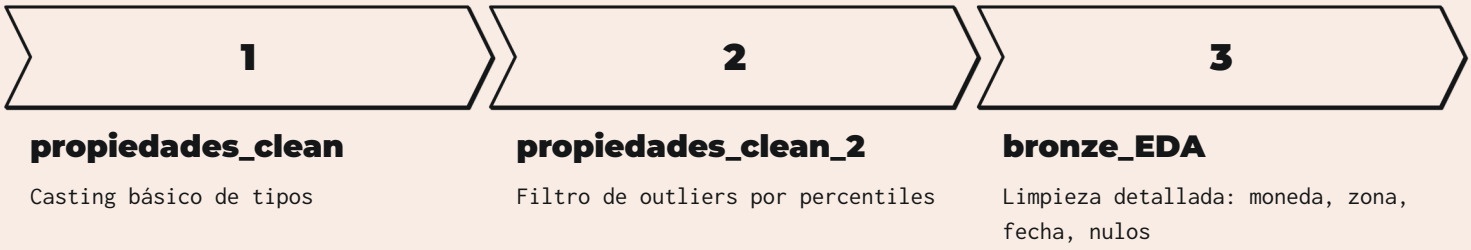
PARTE 3

Transformación Bronze → Silver

Ejercicio 3.1: Ejecutar limpieza de Semana 2

Objetivo: Recrear la cadena de vistas de Semana 2 como punto de partida para Silver.

Contexto: En Semana 2 construiste 3 vistas encadenadas:



Instrucción: Copiá el código de tu notebook de Semana 2 y ejecutalo. Verificá que `bronze_EDA` tiene datos con un `SELECT COUNT(*)`.

CREATE OR REPLACE TEMP VIEW

Crea una vista que solo existe en tu sesión

CAST

Convierte tipos de datos. Si falla, investigá el valor que no convierte

CASE WHEN

Para valores especiales como 999 (antigüedad desconocida)

RLIKE (regex)

Para estandarizar zonas con patrones

Sobre RLIKE:

```
-- Sin regex: 3 líneas para lo mismo
WHEN zona = 'bsas-gba-norte/san-isidro' THEN 'san isidro'
WHEN zona = 'gba-zona-norte--san-isidro' THEN 'san isidro'
WHEN zona = 'san-isidro' THEN 'san isidro'

-- Con regex: 1 línea
WHEN zona RLIKE 'san-isidro' THEN 'san isidro'
```

Para `region` usá `LIKE` con prefijos:

```
WHEN zona LIKE 'bsas-gba-norte/%' THEN 'gba zona norte'
WHEN zona LIKE 'gba-zona-norte--%' THEN 'gba zona norte'
```

PARTE 3 — CONTINUACIÓN

Pipeline bronze_EDA → Silver (paso a paso)

Ejercicio 3.2

Objetivo: Construir el pipeline de tipado + deduplicación + inserción usando CTEs. Trabajá paso a paso — verificá cada CTE antes de avanzar.

1 CTE `datos_tipados`

Aplicá `CAST` a los tipos finales desde `bronze_EDA`. Ejecutá como `SELECT` y verificá que los tipos son correctos.

- `DECIMAL(15,2)` para precio, expensas, m2
- `INT` para ambientes, antigüedad
- `BOOLEAN` para cochera
- Filtrá registros inválidos (`precio > 0`, `m2 > 0`)

2 CTE `datos_deduplicados`

Agregá `ROW_NUMBER() OVER (PARTITION BY precio, url ORDER BY precio)` para detectar duplicados. Ejecutá como SELECT y contá cuántos duplicados encontrás (`WHERE rn > 1`).

3 CTE `datos_finales`

Agregá el mapeo de `partido` y `region` + `precio_por_m2`. Usá como referencia `datasets/zonas_subzonas_case.sql` — tiene el CASE WHEN completo (~90 líneas).

4 INSERT INTO

Armá el `INSERT INTO bootcamp.silver.propiedades` con las 3 CTEs encadenadas. Filtrá solo `WHERE rn = 1`.

Ayudas:

- ¿Qué columnas usás en PARTITION BY para detectar duplicados? Pensá en qué combinación identifica un registro único
- ¿Cómo calculás `precio_por_m2`? ¿Qué pasa si `metros_cuadrados_totales` es NULL?
- ¿Qué registros deberías filtrar antes de insertar y por qué?

PARTE 3 — CONTINUACIÓN

Validación de Datos en Silver

Ejercicio 3.3: Validar datos insertados

Objetivo: Comparar la cantidad de registros entre Bronze y Silver.

Instrucción: Usá `UNION ALL` para combinar conteos de ambas tablas en un solo resultado.

Esperado: Silver debería tener **menos** registros que Bronze — los filtros del pipeline eliminan registros inválidos y duplicados.

Ejercicio 3.4: Verificar calidad de datos en Silver

Objetivo: Confirmar que los filtros del pipeline funcionaron correctamente.

Verificaciones (una query con múltiples conteos):

- **Precios válidos:** no debería haber `precio <= 0`
- **Metros cuadrados válidos:** no debería haber `m2 <= 0`
- **Antigüedad normalizada:** 999 = desconocido (INT)
- **Partidos completos:** no debería haber `partido` NULL o vacío

Pista: `COUNT(CASE WHEN condición THEN 1 END)` cuenta registros que cumplen una condición específica.

PARTE 4

Análisis Silver — Agregaciones

> En Semana 1 usaste `GROUP BY`, `AVG`, `COUNT` y `HAVING` sobre un dataset de ejemplo (NYC Taxi). Ahora aplicás las mismas herramientas pero sobre datos que vos limpiaste y validaste. Esa es la diferencia entre analizar datos de otros y analizar datos que construiste.

Ejercicio 4.1: Métricas por partido

Objetivo: Calcular estadísticas agregadas por partido directamente desde Silver.

Agrupá por: `partido`, `tipo_operacion`, `moneda`

Calculá: `COUNT(*)`, `AVG(precio)`, `MIN(precio)`, `MAX(precio)`, `AVG(precio_por_m2)`

Ayudas:

- ¿Qué función de agregación usarías para el precio promedio?
- ¿Por qué agrupás por partido y no por region? ¿Qué otras agrupaciones podrían ser útiles?
- Usá `HAVING COUNT(*) >= 5` para filtrar partidos con pocos datos

Ejercicio 4.2: Ranking de partidos por precio

Objetivo: Rankear partidos por precio usando window functions.

Pasos:

- Calculá el precio promedio por partido (con CTE o subquery)
- Aplicá `ROW_NUMBER() OVER (PARTITION BY tipo_operacion, moneda ORDER BY precio_promedio DESC)` para crear el ranking
- Ordená por ranking para ver los partidos más caros primero

Ayudas:

- ¿Cómo funciona `ROW_NUMBER()` con `OVER` y `ORDER BY`?
- ¿Qué partido debería tener ranking = 1? ¿El más caro o el más barato?

PARTE 4 — CONTINUACIÓN

Distribución por Ambientes y Verificación del Pipeline

Ejercicio 4.3: Distribución por ambientes

Objetivo: Analizar la oferta por cantidad de ambientes con porcentajes.

Agrupá por: `ambientes`, `tipo_operacion`, `moneda`

01

Contá registros por grupo

Usá `COUNT(*)`

02

Calculá el total general

Usá `SUM(COUNT(*)) OVER(PARTITION BY tipo_operacion, moneda)`

03

Calculá porcentajes

`(COUNT(*) * 100.0) / SUM(COUNT(*)) OVER(...)`

Ayudas:

- ¿Por qué agrupás también por `tipo_operacion` y `moneda`?
- ¿Qué te dice esta distribución sobre el mercado inmobiliario?

PARTE 5

Verificar el Pipeline Completo

> Las queries de Parte 4 son el tipo de análisis que un área de negocio correría sobre sus datos. En Semana 4 vamos a modelar la capa Gold para que cada departamento tenga su propio data mart gobernado — donde pueden generar sus métricas sin tocar Silver directamente.

Ejercicio 5.1: Resumen de objetos por capa

Objetivo: Listar todas las tablas en cada esquema (bronze, silver, gold).

Instrucción: Usá `information_schema.tables` o `SHOW TABLES` con `UNION ALL` para combinar las 3 capas.

Ejercicio 5.2: Resumen de registros por capa

Objetivo: Contar registros en Bronze y Silver para ver el efecto de los filtros.

Instrucción: Usá `UNION ALL` para combinar conteos. La cantidad debería disminuir de Bronze a Silver.

Ejercicio 5.3: Encontrar registros filtrados por el pipeline

Objetivo: Identificar qué datos de Bronze NO llegaron a Silver y por qué.

Instrucción: Escribí una query que cuente registros en Bronze que no cumplen las condiciones del pipeline (`precio <= 0`, `m2 <= 0`, `zona` no mapeada, etc.). Esto demuestra el valor de la capa Silver: los datos problemáticos quedan en Bronze, no contaminan el análisis.

Verificación final: Al completar estos ejercicios, deberías ver claramente cómo los registros disminuyen de Bronze a Silver por los filtros de calidad, y cómo Silver es la base confiable para todo el análisis posterior. En Semana 4, modelamos Gold para que áreas de negocio accedan a sus data marts sin tocar Silver.

Comandos de Verificación — Cheat Sheet

Comando	Descripción	Cuándo usarlo
`SHOW SCHEMAS IN bootcamp`	Lista todos los esquemas del catálogo	Verificar capas Bronze/Silver/Gold
`SHOW TABLES IN bootcamp.silver`	Lista tablas en un esquema	Confirmar que la tabla existe
`DESCRIBE tabla`	Muestra columnas y tipos de datos	Verificar estructura básica
`DESCRIBE EXTENDED tabla`	Muestra info completa + TBLPROPERTIES	Verificar metadata y propiedades
`SELECT COUNT(*) FROM tabla`	Cuenta registros totales	Comparar Bronze vs Silver
`SELECT * FROM tabla LIMIT 10`	Muestra primeros registros	Inspección rápida de datos

Recordatorios Importantes

> **Estándar de la industria:** La Arquitectura Medallion es un ESTÁNDAR DE LA INDUSTRIA.

🥉 Bronze = Crudo

Nunca modifiques los datos originales. Es la fuente de verdad inmutable.

🥈 Silver = Limpio

Aquí haces todo el trabajo pesado de transformación. La calidad en Silver determina la calidad de todo lo demás.

🥇 Gold = Modelado

Fact tables y dimension tables diseñadas para consumo de negocio. Lo construye el ingeniero de datos con el negocio, lo consume el área a través de su capa semántica.

¿Estás atascado?

1. Revisa los tips específicos de ese ejercicio arriba
2. Verifica que completaste correctamente los ejercicios anteriores
3. Ejecuta queries de verificación (`COUNT`, `SELECT LIMIT 10`)
4. Revisa la documentación de Databricks si es un comando específico
5. Pregunta en el canal de Discord del bootcamp

Instructor: **Luciano Argolo** | www.LucianoArgolo.com

www.LucianoArgolo.com